

课程一（15%）

1.环境配置

编译器安装:Visual Studio Code/Pycharm

Python环境管理:Python虚拟环境搭建(conda/venv),推荐安装anaconda/miniconda进行环境管理

<https://blog.csdn.net/ming12131342/article/details/140233867>

验证安装，终端运行 `conda --version`

换源：[ubuntu、conda、pip 换北外源（北京外国语大学开源软件镜像站）](#) [北外临时源-CSDN博客](#)

创建虚拟环境

```
conda create -n speech_env python=3.8
```

```
conda activate speech_env
```

2.安装numpy,matplotlib,librosa,pandas

3.导入librosa,pandas,numpy,matplotlib,IPython

4.使用IPython展示音频

5.使用librosa加载音频,打印加载的音频shape,音频采样率

6.使用matplotlib包绘制音频

7.使用librosa计算音频的幅度谱图,打印幅度谱shape并使用matplotlib进行绘制

8.使用librosa计算并绘制mel谱

9.安装torch,torchaudio

<https://pytorch.org/>

10.使用torchaudio加载音频,计算mel谱并绘制



image.png



image-2.png

课程二 (30%)

自行构建幅度谱

1.librosa加载音频

2.实现预加重函数

预加重处理相当于将语音信号通过一个高通滤波器，用来提升高频部分，因为语音信号的高频能量通常较低，预加重可以平衡频谱，便于后续分析。

$$y[t]=x[t]-\alpha \cdot x[t-1]$$

α 通常取0.97

3.实现分帧函数

通常帧长25ms,帧位移10ms,为了确保所有帧采样数相等,需要对信号最后进行填充

查看分帧后的shape,分帧后shape变成二维

4.实现加窗函数

hamming窗提示: `numpy.hamming()`

加窗方式: `frame_sig_window(n)=frame_sig(n)·window(n)`

5.实现短时傅里叶变换函数得到幅度谱

nfft通常为256或512

STFT提示: `numpy.fft.rfft()`

幅度谱需要取模

6.取对数得到可绘制查看的幅度谱,并绘制

$$F_{\text{dB}} = 20 \times \log_{10}(F)$$

课程三 (45%)

实现FBank和MFCC

1.实现mel滤波

人耳对低频更敏感,但对高频变化的分辨率较低,所以要使用Mel频率刻度来更符合人耳的听觉特性.

奈奎斯特采样定理:对于一个采样率为 f_s 的数字音频系统,它能无失真表示的最高频率是 $f_s/2$,这个频率称为奈奎斯特频率。

n_{filter} 取40, n_{fft} 取512

$$M_{\min} = 0$$

$$M_{\max} = 2595 \log_{10} \left(1 + \frac{f_s}{2 \times 700} \right)$$

$$M_i = \text{linspace}(M_{\min}, M_{\max}, n_{\text{filter}} + 2)$$

$$f_i = 700 \left(10^{M_i/2595} - 1 \right)$$

$$H_m(k) = \begin{cases} 0, & k < f(m-1) \text{ or } k > f(m+1) \\ \frac{k - f(m-1)}{f(m) - f(m-1)}, & f(m-1) \leq k \leq f(m) \\ \frac{f(m+1) - k}{f(m+1) - f(m)}, & f(m) < k \leq f(m+1) \end{cases}$$

$$\text{filter_banks} = P \cdot H_m^T$$

查看最后维度

3.取对数得到可绘制查看的梅尔谱,并绘制,注意矩阵维度,可能需要转置

$$P_{\text{dB}} = 20 \times \log_{10}(P)$$

4.使用fbank经过离散余弦变换函数得到mfcc,并绘图

课程四 (加分项 : 10%)

基于预训练模型的深度音频特征提取

在前面的实验中，你已经学会了如何手动提取传统的音频特征（MFCC、FBank）。近年来，基于深度学习的预训练模型（如 **Wav2Vec2**、**HuBERT**、**Whisper**）可以从音频中自动学习到更强大的特征表示，广泛应用于语音识别、说话人识别等任务。本实验需要你加载一个预训练的 **Wav2Vec2** 或 **HuBERT** 模型（二选一），用它来提取示例音频LJ001-0011.wav的深度特征。

Wav2Vec2模型：

torchaudio文档：

<https://docs.pytorch.org/audio/stable/generated/torchaudio.models.Wav2Vec2Model.html>

Hugging Face Transformers文档：

https://huggingface.co/docs/transformers/model_doc/wav2vec2

HuBERT模型：

github仓库：<https://github.com/facebookresearch/fairseq/tree/main/examples/hubert>

Hugging Face Transformers文档：

https://huggingface.co/docs/transformers/model_doc/hubert

注：HuBERT和Wav2Vec2模型对于输入音频的采样率均有要求，你可能需要对音频进行重采样以符合模型的要求。